Linguaggi e compilatori

Corso di Laurea in Informatica

Mauro Leoncini

A.A. 2023/2024

1. Generazione dell'AST
   - Architettura del front-end
   - Rappresentazione astratta di un programma
   - Verso l'ASD di Kaleidoscope 1.0

Linguaggi e compilatori

Organizzazione modulare

- Il nostro obiettivo è progettare (e programmare) un front-end per la prima versione di Kaleidoscope (che per comodità chiameremo *Kaleidoscope 1.0*)
- L'output desiderato per il frot-end è, al momento, solo l'*Abstract Syntax Tree* (AST) del programma in input
- Iniziamo con delineare la struttura dell'applicazione
- Potremmo scrivere tutto in due sole unità di programma: lo scanner e il parser, includendo in quest'ultimo un *main program* che coordini tutte le attività
- Proponiamo invece una soluzione *modulare*, più facilmente comprensibile, manutenibile e "debuggabile"
- La stessa architettura modulare costituisce da sola una migliore documentazione dell'applicazione

I moduli dell'applicazione

- L'applicazione consta dunque dei seguenti moduli
- Un modulo *scanner* per la lettura del file e l'analisi lessicale, generato utilizzando `Flex`
- Un modulo per il *parsing* e la costruzione dell'AST, generato utilizzando `Bison`
- Un modulo *driver*, che include tutte le classi C++ di cui i nodi dell'AST costituiscono istanze
- Il modulo driver definisce anche una classe (omonima) che rappresenta il c.d. *parsing context*, ovvero una struttura dati che consente un'efficace condivisione di dati fra parser e scanner (e main program) prescindendo dall'uso di variabili globali
- Un *client* che include il *main program* e il cui compito è di effettuare il parsing dei parametri forniti dall'utilizzatore nella riga di comandi e di "lanciare" la compilazione

Il programma client

```
#include <iostream>
#include "driver.hpp"

int main (int argc, char *argv[])
{  driver drv;
   for (int i = 1; i < argc; ++i)
   if (argv[i] == std::string ("-p"))
      drv.trace_parsing = true;
   else if (argv[i] == std::string ("-s"))
      drv.trace_scanning = true;
   else if (!drv.parse (argv[i])) {
      drv.root->visit();
      std::cout << std::endl;
   } else return 1;
   return 0;
}
```

Il client e l'uso della classe `driver`

- Come si vede, l'architettura modulare consente di avere un client molto semplice
- A parte le ovvie operazioni di parsing della linea di comando, dal codice presentato si può iniziare a comprendere l'uso della classe `driver`
  - In due opportune variabili della classe, `trace_scanning` e `trace_parsing`, il driver inserisce informazioni che saranno utlizzate dallo scanner e (indirettamente) dal parser
  - Un metodo della classe (`parse`) consente di dare inizio al processo di compilazione
  - A fine compilazione, la variabile `root` "contiene" la radice dell'AST, da cui deve iniziare il processo di visita
- Le prossime due slide riportano la definizione della classe `driver`; quelle immediatamente seguenti mostrano invece "graficamente" l'architettura generale

La classe driver: definizione

```
class driver {
public:
   driver();
   void scan_begin();      // Implementata nello scanner
   void scan_end();        // Implementata nello scanner
   int parse (const std::string& f);

   RootAST* root;          // Radice dell'AST costruito
   yy::location location; //
   std::string file;       // File sorgente

   bool trace_parsing;     // Per trace debug nel parser
   bool trace_scanning;    // Per trace debug nello scanner
};
```

La classe driver: implementazione (parziale)

```
driver::driver(): trace_parsing (false),
                  trace_scanning (false) {};

int driver::parse (const std::string &f) {
   file = f;
   location.initialize(&file);
   scan_begin();
   yy::parser parser(*this);
   parser.set_debug_level(trace_parsing);
   int res = parser.parse();
   scan_end();
   return res;
}
```

File coinvolti

client.cpp

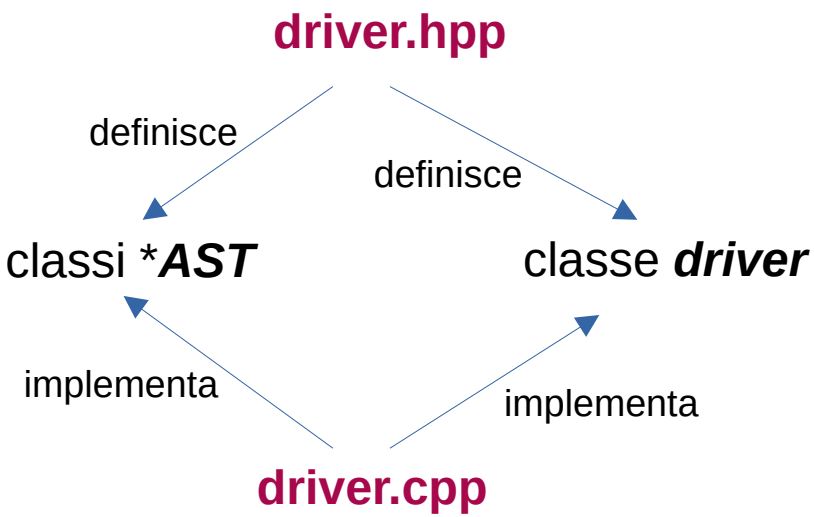

parser.yy

scanner.ll

Compilazione di Lexer e Parser

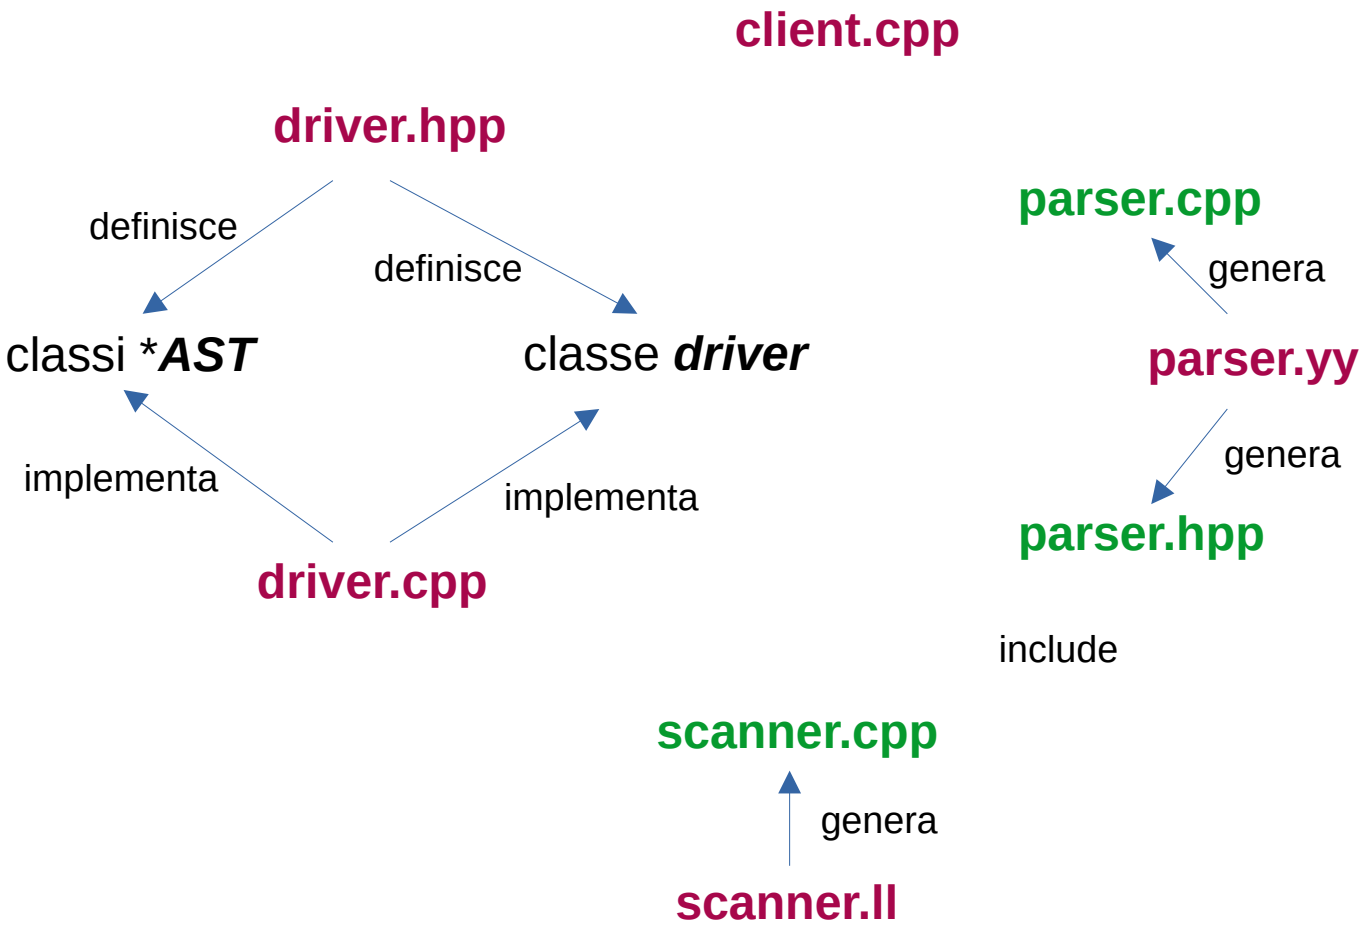

Dopo la compilazione

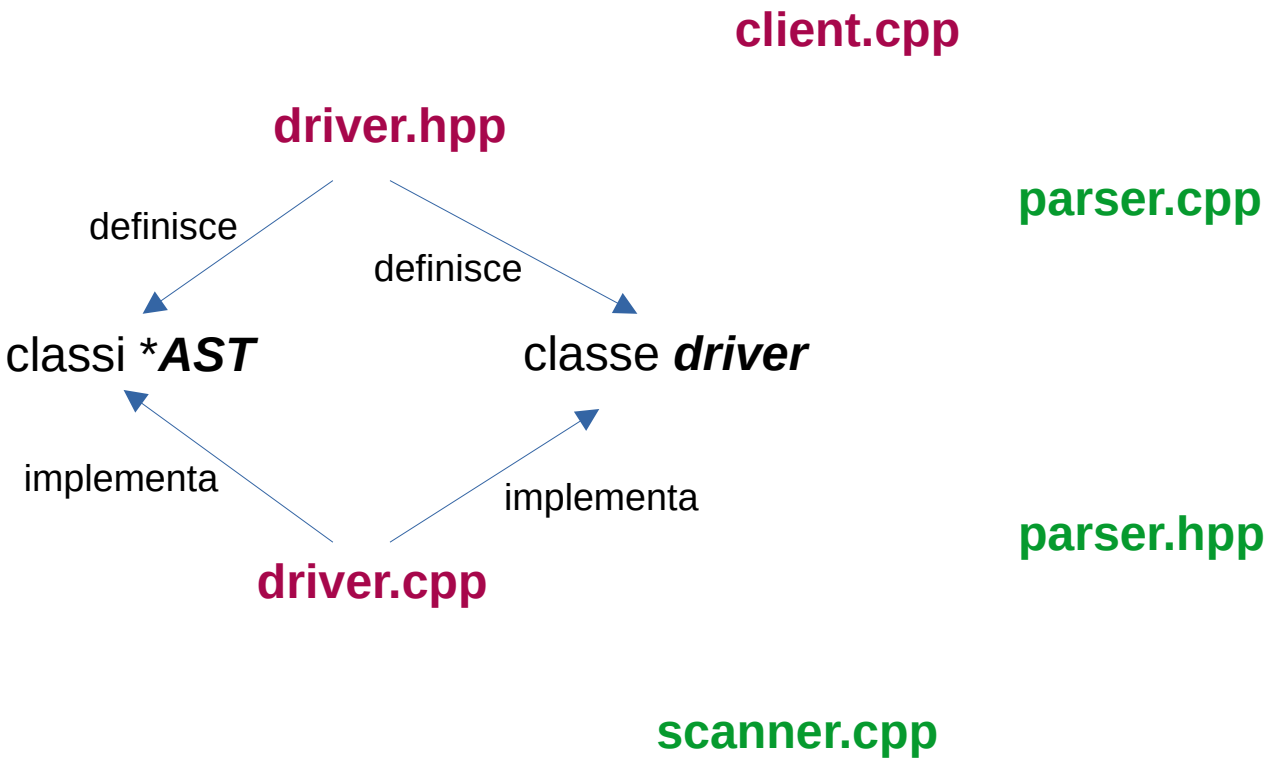

Dipendenze

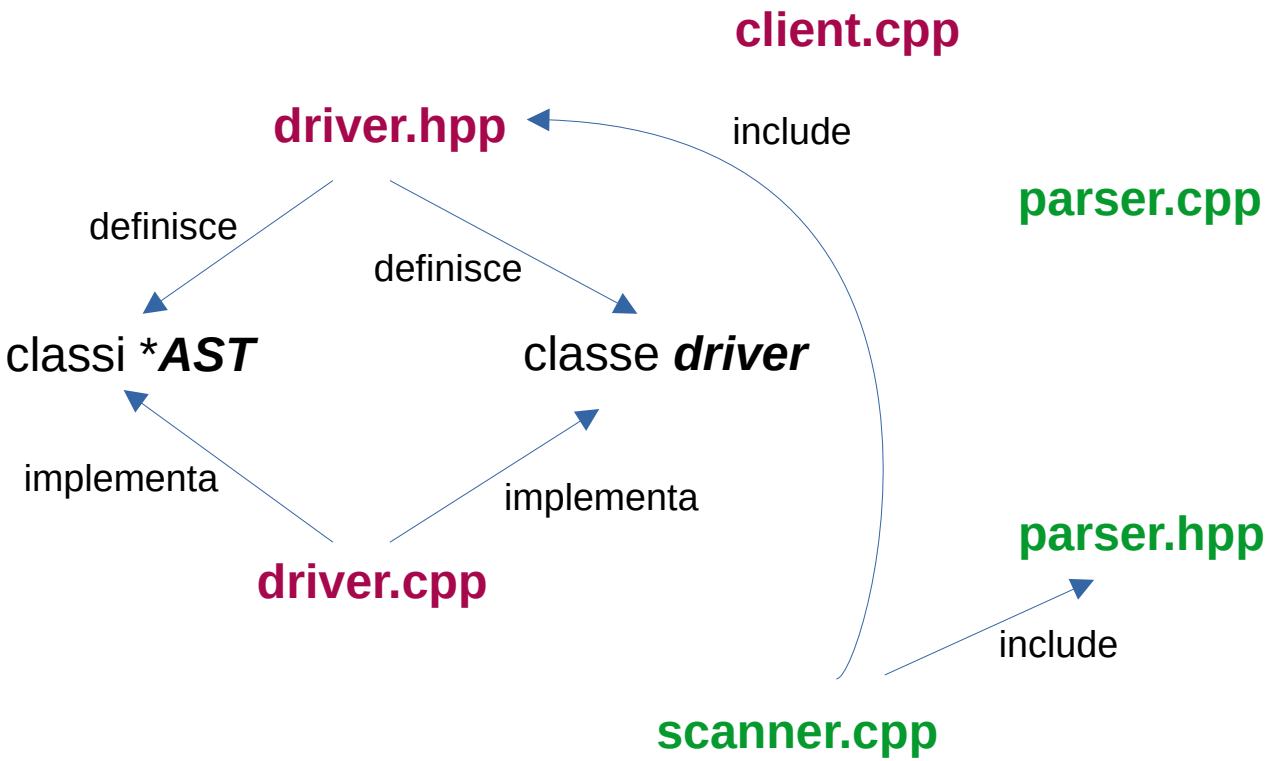
client.cpp
driver.hpp
include
parser.cpp
definisce
definisce
classi *AST
classe driver
implementa
implementa
parser.hpp
driver.cpp
include
scanner.cpp

Dipendenze

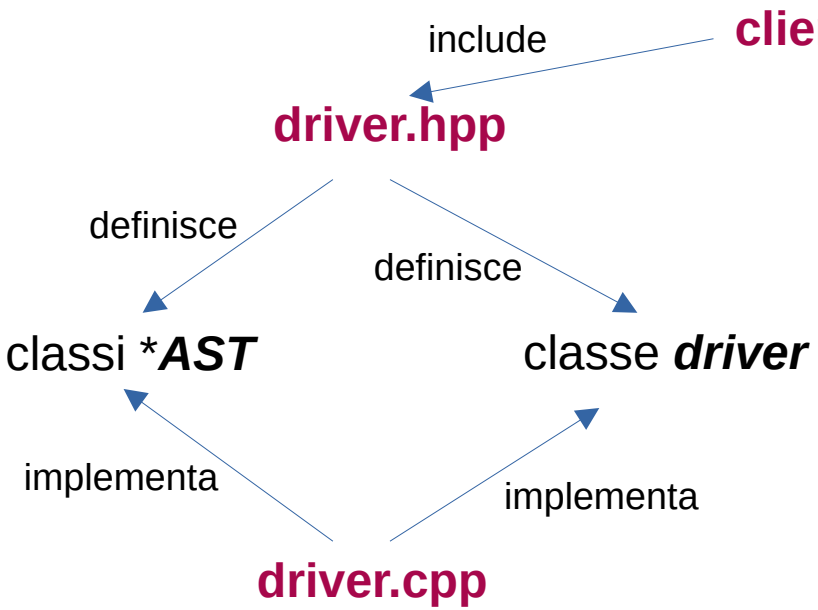

parser.cpp

parser.hpp

scanner.cpp

Esistenza di una dipendenza "circolare"

- Le prossime due slide mostrano l'esistenza di una mutua dipendenza di `driver` e `parser`
- Per un verso, infatti, il parser necessita di includere `driver.hpp`
- Questa è la dipendenza più evidente perché il driver include le classi `*AST` (che il parser deve usare per costruire l'albero sintattico) e la classe `driver` che funge da contesto
- Tuttavia, anche il driver necessita di includere `parser.hpp`:
  - perché è nel parser che è definita la classe `location` e questa classe è un fondamentale dato da inserire nel contesto
  - perché la definizione del tipo di ritorno di `yylex` è una enumerazione dei vari token name, che sono definiti dal `parser`
- Per risolvere la circolarità, `Bison` ha la direttiva `%code requires`, che consente di inserire *forward declaration* nell'header file

Dipendenze

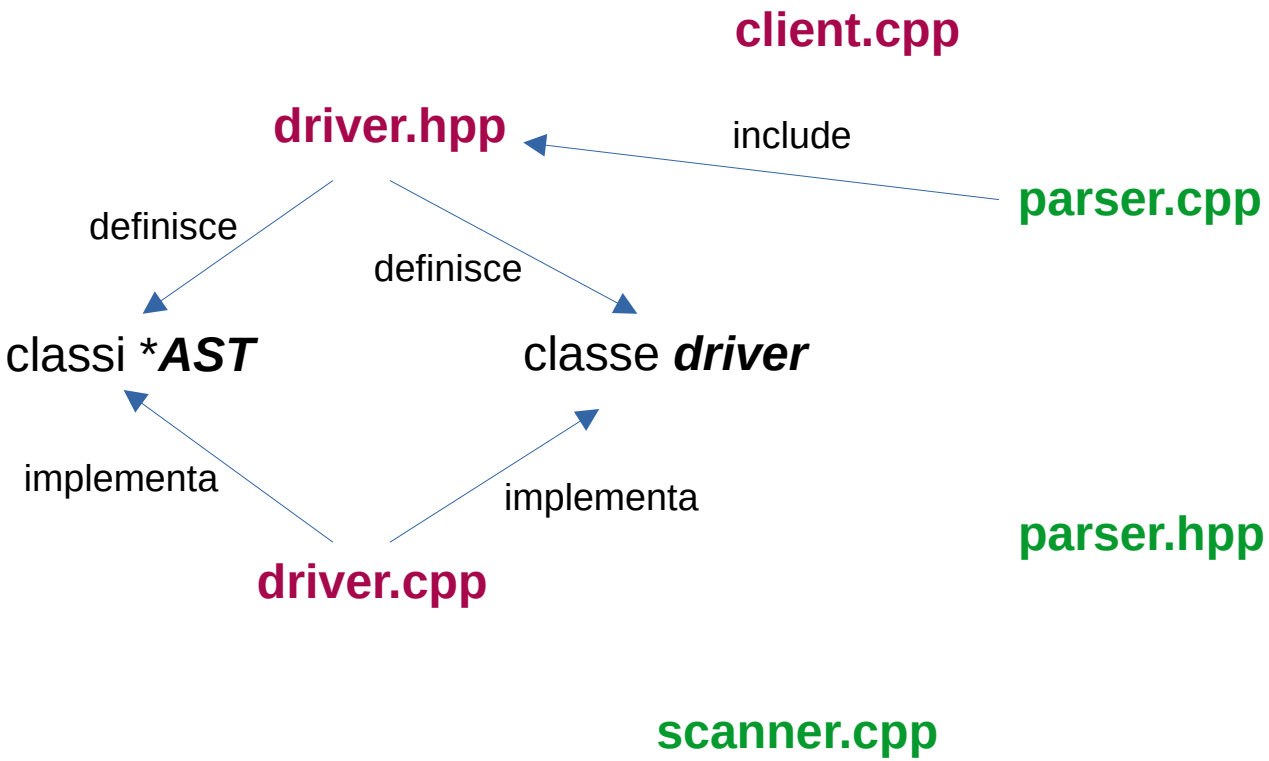
client.cpp
driver.hpp
include
parser.cpp
definisce
definisce
classi *AST
classe driver
implementa
implementa
parser.hpp
driver.cpp
scanner.cpp

Dipendenze

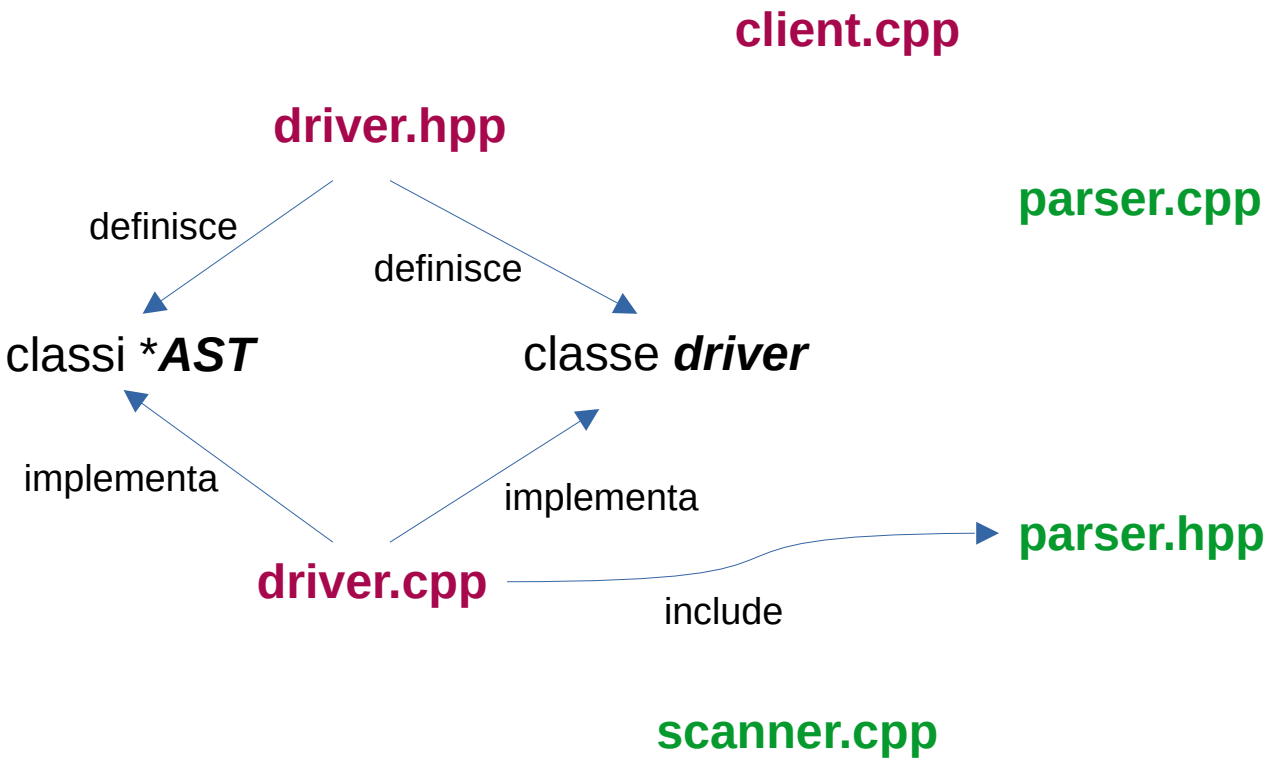
client.cpp
driver.hpp
parser.cpp
definisce
definisce
classi *AST
classe driver
implementa
implementa
parser.hpp
driver.cpp
include
scanner.cpp

Il flusso informativo

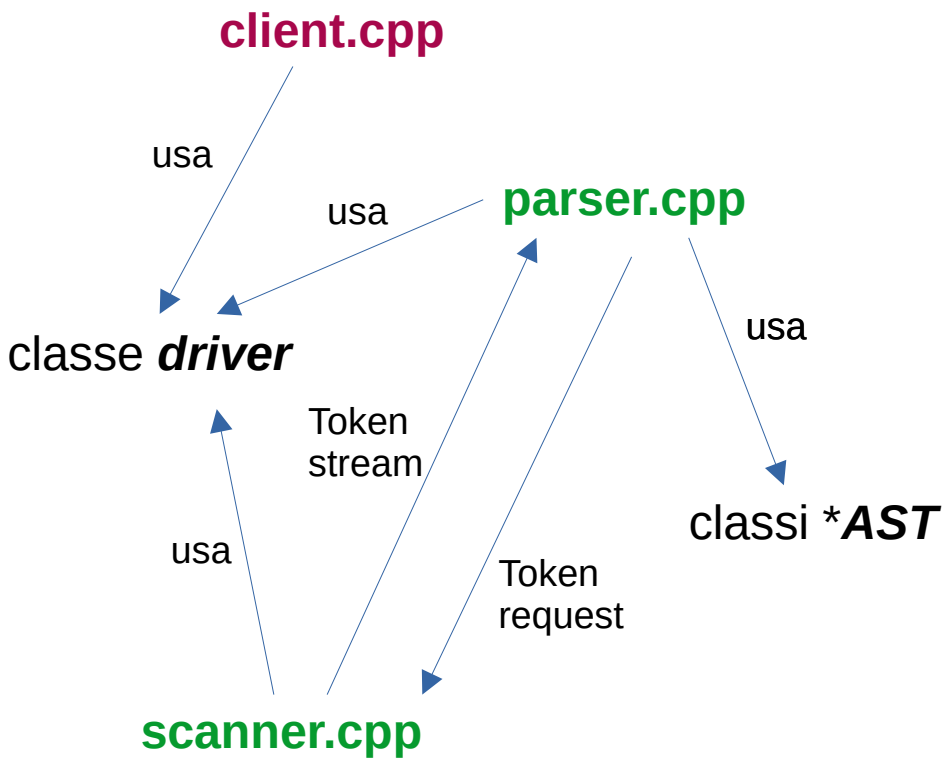

Linguaggi e compilatori

AST

- L'*Abstract Syntax Tree* (*ASD*) di un'espressione è un albero radicato in cui i nodi interni rappresentano operatori mentre le foglie rappresentano operandi
- Il numero di figli di un nodo interno corrisponde all'*arietà* (cioè il numero di operandi) dell'operatore associato a quel nodo interno
- L'albero riflette in modo naturale la struttura "ricorsiva" di un'espressione: come un operatore può avere, come operando, un'intera sotto-espressione, così il figlio di un nodo interno può essere a sua volta radice di un sotto-albero
- La stessa struttura gerarchica impone poi un'ordine alle operazioni al fine di valutare l'espressione: se un nodo (interno) X è un discendente di Y, allora l'operazione rappresentata da Y deve essere logicamente eseguita prima di (quella di) X
- L'intera espressione rappresentata da un ASD può infatti essere valutata mediante una visita dell'albero in *ordine posticipato*

Esempio

- L'ASD dell'espressione $x \cdot \sqrt{1+y} + 2 \cdot y^2$ è

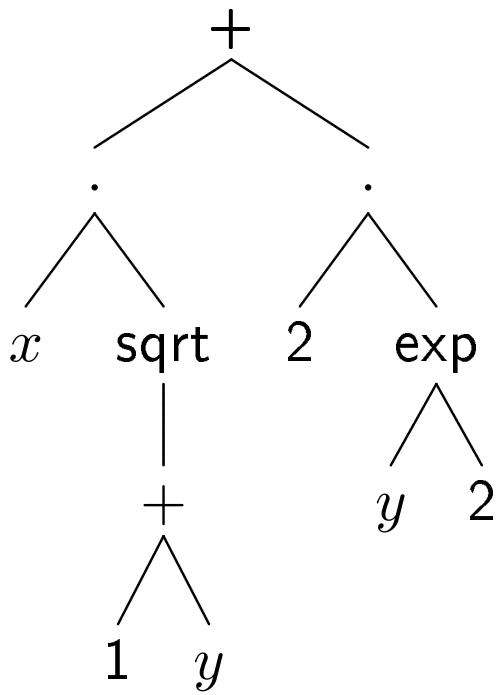

ASD per strutture programmative

- Non solo le espressioni aritmetiche o logiche ma anche le più importanti strutture di controllo (condizionali, iterazioni determinate e indeterminate, oltre che assegnamento e sequenza) possono essere descritte mediante un albero
- Ad esempio, la struttura condizionale "a due vie":

  if ⟨condition⟩ {⟨true section⟩} else {⟨false section⟩}

  può essere rappresentata mediante il seguente ASD

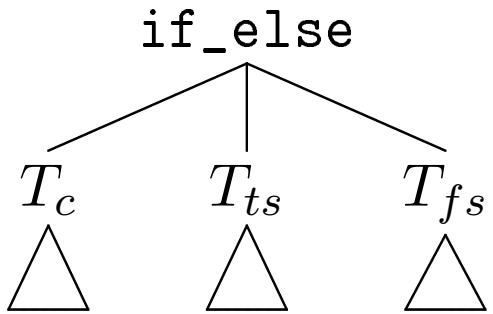

dove `if_else` è un *codice* che indica il condizionale a due vie mentre T_c, T_{tc} e T_{fc} sono rispettivamente gli ASD per la condizione di controllo e per le istruzioni della sezioni true e false

ASD per strutture programmative

- Altri due esempi: sequenza e iterazione indeterminata (`while`)

$\langle$statement1$\rangle$; {$\langle$rest$\rangle$} while $\langle$condition$\rangle$ {$\langle$body$\rangle$}

dove Ts indica l'ASD che rappresenta $\langle$statement1$\rangle$, T_r l'ASD che rappresenta tutte le istruzioni che seguono $\langle$statement1$\rangle$ (il *resto* del programma) e, infine, T_c e T_b sono gli ASD che descrivono la condizione di controllo del `while` e il suo "body".

Un semplice esempio "completo"

- L'ASD per il frammento di codice:

```
x=10;
y=1;
while (x>0) {
  x = x-1;
  y = 2*y;
}
```

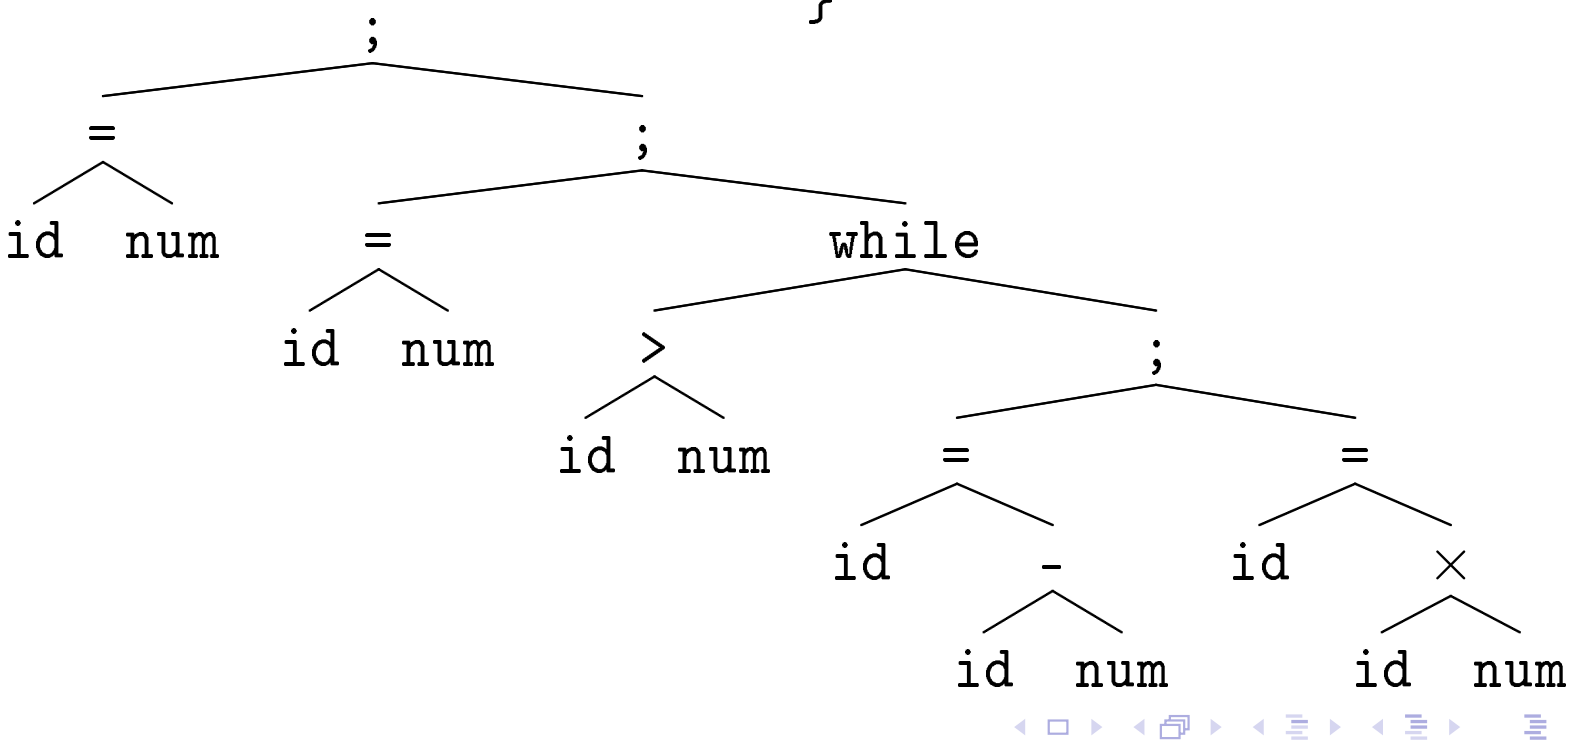

Qualche osservazione

- Le foglie del precedente ASD denotano identificatori o valori numerici
- Questa è la situazione generale, nel senso che le foglie denotano *token* che possiedono un valore lessicale (il *token value*)
- Nella foglia viene memorizzato sia il *token name* (evidenziato nella figura) sia tipicamente un "puntatore" ad una opportuna *entry* della *symbol table*, dove appunto è registrato il valore lessicale del token
- Anche se, come chiarito dagli esempi, un ASD può essere costruito pure per tipici programmi imperativi, la presenza di istruzioni di controllo del flusso di esecuzione rende tuttavia sensibilmente diverso il processo di "interpretazione" (rispetto al caso di semplici espressioni)
- Una semplice visita in post-ordine non è infatti in generale sufficiente per "eseguire" il programma descritto dall'ASD
- Essa è però sufficiente nel caso in cui l'obiettivo sia di generare codice, piuttosto che interpretare il programma

Linguaggi e compilatori

La grammatica per il parser di Bison

- Ricordiamo che Kaleidoscope 1.0 deve permettere la scrittura di programmi che includono solo pochi tipi differenti di "istruzioni":
  - definizioni di funzioni esterne
  - dichiarazioni di funzioni
  - espressioni aritmetiche, che costituiscono il body delle funzioni dichiarate
- Un programma può includere un numero arbitrario di tali "istruzioni", separate da punto e virgola
- Per kaleidoscope 1.0 abbiamo visto una grammatica adatta al parsing top-down
- Qui riscriviamo la grammatica "pensando" all'algoritmo di parsing incluso in Bison, che è di tipo *LR*

Grammatica *LR* Kaleidoscope 1.0

$$
\begin{array}{rcl}
\langle \text{program} \rangle & ::= & \langle \text{top} \rangle \text{ ';' } \langle \text{program} \rangle \mid \epsilon \\
\langle \text{top} \rangle & ::= & \langle \text{def} \rangle \mid \langle \text{external} \rangle \mid \langle \text{expr} \rangle \mid \epsilon \\
\langle \text{def} \rangle & ::= & \mathit{def} \ \langle \text{proto} \rangle \langle \text{expr} \rangle \\
\langle \text{external} \rangle & ::= & \mathit{extern} \ \langle \text{proto} \rangle \\
\langle \text{proto} \rangle & ::= & \mathit{id} \text{ '(' } \langle \text{idseq} \rangle \text{ ')'} \\
\langle \text{idseq} \rangle & ::= & \mathit{id} \ \langle \text{idseq} \rangle \mid \epsilon \\
\langle \text{expr} \rangle & ::= & \langle \text{expr} \rangle \text{ '+' } \langle \text{expr} \rangle \mid \langle \text{expr} \rangle \text{ '-' } \langle \text{expr} \rangle \mid \\
 & & \langle \text{expr} \rangle \text{ '*' } \langle \text{expr} \rangle \mid \langle \text{expr} \rangle \text{ '/' } \langle \text{expr} \rangle \mid \\
 & & \text{'(' } \langle \text{expr} \rangle \text{ ')'} \mid \langle \text{idexpr} \rangle \mid \mathit{number} \\
\langle \text{idexpr} \rangle & ::= & \mathit{id} \mid \mathit{id} \text{ '(' } \langle \text{optexpr} \rangle \text{ ')'} \\
\langle \text{optexpr} \rangle & ::= & \langle \text{exprlist} \rangle \mid \epsilon \\
\langle \text{exprlist} \rangle & ::= & \langle \text{expr} \rangle \mid \langle \text{expr} \rangle \text{ ',' } \langle \text{exprlist} \rangle
\end{array}
$$

Qualche osservazione sulla grammatica

- Si nota subito che, in vista del parsing *LR*, non è stato necessario introdurre la (non elegante) soluzione di avere identificatori diversi per funzioni e variabili
- Una grammatica per il parsing LR può avere infatti "prefissi comuni"
- Riguardo l'uso di produzioni ambigue per le espressioni ricordiamo (si vedano le slide della lezione introduttiva a Bison) che l'ambiguità viene risolta con l'uso delle direttive `%left` e `%right`
- Accorpando le produzioni per le espressioni, abbiamo eliminato alcuni simboli non terminali "intermedi", inutili nell'ottica della costruzione dell'AST

I nodi dell'AST

- Dal punto di vista "programmativo", l'AST altro non è che una struttura dati e dunque la prima decisione da prendere riguarda proprio la struttura da utilizzare
- L'idea è di rappresentare ogni nodo come *oggetto* di una classe
- La classe di appartenenza di un nodo può variare (naturalmente in dipendenza di ciò che il nodo vuole rappresentare), tuttavia tutte le classi dovranno ereditare da una superclasse comune
- Come vedremo, con qualche eccezioni, le classi che andremo a definire corrisponderanno ai simboli non terminali della grammatica
- In generale non esiste però una corrispondenza uno-a-uno fra classi e non terminali
- Inizieremo a riflettere su come rappresentare le espressioni

Rappresentazione delle espressioni

- Negli esempi di AST che abbiamo visto all'inizio esistevano apparentemente nodi diversi anche solo per operatori differenti
- Tale distinzione non deve necessariamente portare all'introduzione di più classi, che differirebbero solo per il tipo di operazioni
- Per le espressioni introdurremo invece una classe da cui deriveremo 4 classi, corrispondenti a: (1) operatori binari, (2) variabili, (3) costanti numeriche e (4) chiamata di funzione
- Le 4 sottoclassi rappresentano altrettanti "elementi" costituenti un'espressione. Esse rappresentano però caratteristiche diverse:
  - variabili e costanti numeriche corrispondono a foglie dell'ASD e sono elementi con valore lessicale (di natura differente)
  - gli operatori binari denotano nodi interni con due figli; tralasciando il particolare operatore, richiedono tutti lo stesso trattamento
  - come variabili e costanti, anche una chiamata di funzione etichetta una foglia di un AST ma il trattamento degli argomenti (che naturalmente sono a loro volta espressioni) richiede un collegamento ad un numero arbitrario di altri ASD

La gerarchia completa

- In tutto introdurremo 9 classi, così organizzate

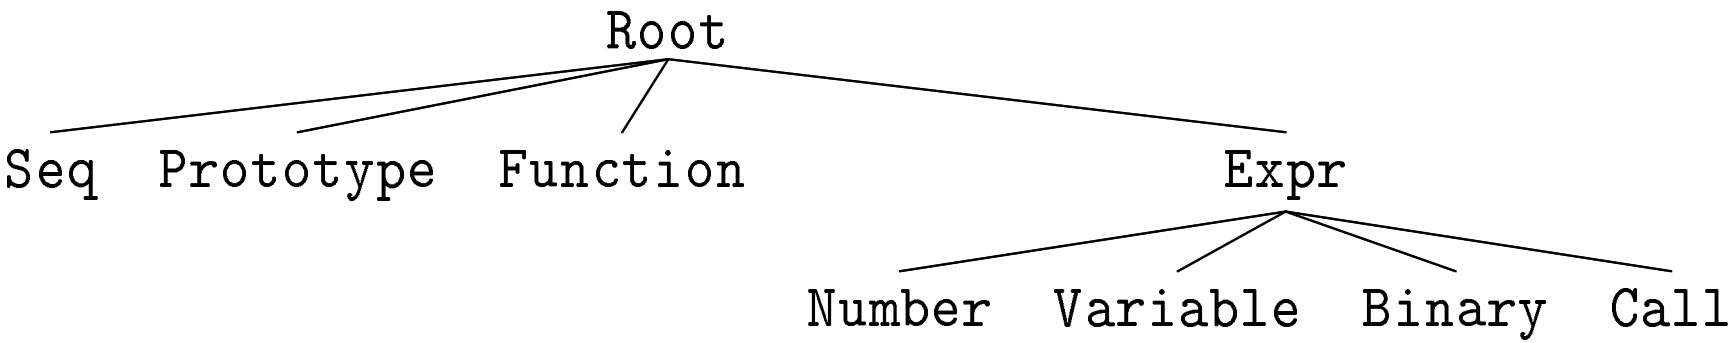

- I nomi effettivi che daremo alle classi sono leggermente differenti rispetto alla figura (dove sno stati "accorciati" per ragioni di spazio)
- Tutti i nomi hanno cioè il suffisso `AST` che, per le sottoclassi di `Expr`, diviene `ExprAST`
- Le classi vengono definite nel file `driver.hpp` mentre l'implementazione dei metodi è data nel file `driver.cpp`
- Il driver è essenzialmente l'applicazione (in questo caso un front-end per Kaleidoscope 1.0) che coordina le attività di parser e lexer

La classe RootAST

- La classe base della gerarchia include solo metodi *virtuali* (si veda la prossima slide per un veloce "ripasso" sull'uso di tali metodi)

```
typedef std::variant<std::string,double> lexval;
const lexval NONE = 0.0;

class RootAST {
public:
    virtual ~RootAST() = default;
    virtual RootAST *left() {return nullptr;};
    virtual RootAST *right() {return nullptr;};
    virtual lexval getLexVal() {return NONE;};
    virtual void visit() {};
};
```

- I metodi saranno opportunamente ridefiniti nelle sottoclassi

Una digressione: metodi virtuali e loro utilizzo

- Si definisce `virtuale` un metodo dichiarato all'interno di una *classe base* e ridefinito (*overriden*) in una *classe derivata*
- Si tratta di uno strumento per implementare *polimorfismo* a tempo di esecuzione
- Per varie ragioni, può essere necessario fare riferimento ad un metodo M di una classe derivata D usando un "puntatore" il cui tipo è quello di una classe base B
- In questo caso, tecnicamente, il compilatore potrebbe sollevare un'eccezione se B non definisce M oppure se la definisce in modo diverso
- Se M è definita in B come virtuale, a tempo di esecuzione viene (cercata e) chiamata la funzione corretta definita in D
- Per i distruttori questa "costruzione" è di fatto obbligatoria (per far sì che venga distrutto l'oggetto giusto)

La classe base per le espressioni

- La classe `ExprASt` non include metodi virtuali e potrebbe in teoria non essere presente
- In tal caso tutte le classi erediterebbero direttamente da `RootAST`
- La classe viene introdotta principalmente per una maggiore "pulizia" del progetto complessivo
- Consideriamo il caso di un'espressione E costituita, ad es., dalla somma di due (sotto)-espressioni E_1 ed E_2
- E_1 ed E_2 possono essere di uno qualsiasi dei 4 tipi che abbiamo individuato (numero, identificatore, espressione binaria o chiamata di funzione)
- È chiaro dunque che ci deve essere una classe comune per indicare queste espressioni
- Se la classe fosse direttamente `RootAST`, potrebbe risultare lecito comporre un'espressione anche con oggetti delle altre tre classi, ad esempio `SeqAST`, ma questo non sarebbe corretto

La classe NumberExprAST

Definizione

```
class NumberExprAST : public ExprAST {
private:
   double Val;
public:
   NumberExprAST(double Val);
   void visit();
   lexval getVal() const;
};
```

Implementazione

```
NumberExprAST::NumberExprAST(double Val): Val(Val) {};
void NumberExprAST::visit() {
   std::cout << Val << " "; };
lexval NumberExprAST::getLexVal() {
   lexval lval = Val; return lval; };
```

La classe VariableExprAST

Definizione

```
class VariableExprAST : public ExprAST {
private:
   std::string Name;
public:
VariableExprAST(std::string &Name);
void visit();
lexval getLexVal(); };
```

Implementazione

```
VariableExprAST::variableExprAST(std::string &Name):
         Name(Name) {};
void VariableExprAST::visit() {
    std::cout << Name << " "; };
lexval VariableExprAST::getLexVal() {
   lexval lval = Name; return lval; };
```

La classe BinaryExprAST: definizione

```
class BinaryExprAST : public ExprAST {
private:
    char Op;
    ExprAST* LHS;
    ExprAST* RHS;
public:
    BinaryExprAST(char Op, ExprAST* LHS, ExprAST* RHS);
    ExprAST* left();
    ExprAST* right();
    void visit();
};
```

La classe BinaryExprAST: implementazione

```
BinaryExprAST::BinaryExprAST(char Op, ExprAST* LHS,
        ExprAST* RHS): Op(Op), LHS(LHS), RHS(RHS) {};
ExprAST* BinaryExprAST::left() {
   return LHS;
};
ExprAST* BinaryExprAST::right() {
   return RHS;
};
void BinaryExprAST::visit() {
   std::cout << "(" << Op << " ";
   LHS->visit();
   if (RHS!=nullptr) RHS->visit();
   std::cout << ")";
};
```

La classe CallExprAST: definizione

```
class CallExprAST : public ExprAST {
private:
    std::string Callee;
    std::vector<ExprAST*> Args;

public:
    CallExprAST(std::string Callee,
                std::vector<ExprAST*> Args);
    lexval getLexVal() const;
    void visit();
};
```

La classe CallExprAST: implementazione

```
CallExprAST::CallExprAST(std::string Callee,
                         std::vector<ExprAST*> Args): Callee(Callee),
                         Args(std::move(Args)) {};
lexval CallExprAST::getLexVal() const {
   lexval lval = Callee;
   return lval;
};
void CallExprAST::visit() {
    std::cout<< std::get<std::string>(getLexVal())<< "( ";
    for (ExprAST* arg : Args) {
       arg->visit();
    };
    std::cout << ')';
};
```

Le altre classi

- Le ultime tre classi sono di natura differente
- Una prima classe, `SeqAST`, rappresenta la sequenza di istruzioni
- Negli AST che andremo a costruire, gli oggetti di tipo `SeqAST` costituiscono la "dorsale" (con linguaggio figurato, diciamo il *versante destro* dell'AST)
- Le altre due classi rappresentano la definizione di funzioni (classe `FunctionAST`) e la definizione di *prototipi* di funzione (classe `PrototypeAST`), quest'ultima utilizzata nella definizione della prima

La classe SeqAST: definizione

```
class SeqAST : public RootAST {
private:
    RootAST* first;
    RootAST* continuation;

public:
    SeqAST(RootAST* first, RootAST* continuation);
    RootAST *left();
    RootAST *right();
    void visit();
};
```

La classe SeqAST: implementazione

```
SeqAST::SeqAST(RootAST* first, RootAST* continuation):
                first(first), continuation(continuation) {};
RootAST* SeqAST::left() { return first; };
RootAST* SeqAST::right() { return continuation; };
void SeqAST:: visit() {
   if (first != nullptr) {
      first->visit();
   } else {
      if (continuation == nullptr) {
        return;
      };
   };
   std::cout << ";";
   continuation->visit();
};
```

La classe PrototypeAST: definizione

```
class PrototypeAST : public RootAST {
private:
    std::string Name;
    std::vector<std::string> Args;

public:
    PrototypeAST(std::string Name, std::vector<std::string>
    lexval getLexVal() const;
    const std::vector<std::string> &getArgs() const;
    void visit();
    int argsize();
};
```

La classe PrototypeAST: implementazione

```
PrototypeAST::PrototypeAST(std::string Name,
                           std::vector<std::string> Args):
                           Name(Name), Args(std::move(Args)) {};
lexval PrototypeAST::getLexVal() const {
   lexval lval = Name; return lval; };
const std::vector<std::string>& PrototypeAST::getArgs()
   const { return Args; };
void PrototypeAST::visit() {
   std::cout << "extern " << Name << "( ";
   for (auto it=Args.begin(); it!=Args.end(); ++it) {
      std::cout << *it << ' '; };
   std::cout << ')';
};
int PrototypeAST::argsize() {
   return Args.size(); };
```

La classe FunctionsAST: definizione

```
class FunctionAST : public RootAST {
private:
    PrototypeAST* Proto;
    ExprAST* Body;
    bool external;

public:
    FunctionAST(PrototypeAST* Proto, ExprAST* Body);
    void visit();
    int nparams();
};
```

La classe FunctionAST: implementazione

```
FunctionAST::FunctionAST(PrototypeAST* Proto,
      ExprAST* Body): Proto(Proto), Body(Body) {
   if (Body == nullptr) external=true;
   else external=false; };
void FunctionAST::visit() {
   std::cout << std::get<std::string>
       (Proto->getLexVal()) << "( ";
   for (auto it=Proto->getArgs().begin();
        it != Proto->getArgs().end(); ++it) {
      std::cout << *it << ' ';
   };
   std::cout << ')';
   Body->visit();
};
int FunctionAST::nparams() {
   return Proto->argsize(); };
```